欧阳 Yang Ou

高级算法工程师 · 哔哩哔哩
内容安全 / VLM 后训练 / 多模态内容理解

上海
ouyang980107@163.com
ORCID: 0000-0002-1282-9022

专业定位

专注**安全业务、VLM 后训练与细粒度内容理解**。在哔哩哔哩负责内容安全模型及审核多模态大模型能力，覆盖视频、图文、直播、社区与推荐场景。擅长将模糊业务规则转化为可学习的标签、训练目标和评估体系，从数据构建、模型训练到线上部署完整推进。持续将业务问题沉淀为研究课题，形成论文、专利与可复用的算法能力。

科研积累　**4 篇期刊论文、5 篇在投研究、5 项专利相关成果**；参与获得 **ICCV-CLVL 2025 Reliable VQA Challenge 第一名**。

核心技术能力

后训练与推理　监督微调（SFT）、强化学习与可验证奖励、On-Policy Distillation（OPD）、生成与分类联合训练、Adaptive CoT、推理成本优化。

多模态理解　图像、文本与上下文联合建模；细粒度多标签识别、风险严重度排序、结构化取证、幻觉控制与可靠视觉问答。

数据与工程　人机协同数据生产、困难样本挖掘、可控数据合成、模型蒸馏、召回与排序架构、训练及评估工具建设。

任职与代表项目

2022.06–至今　**高级算法工程师**, 哔哩哔哩, 内容安全与多模态算法

含 2022.06–2023.02 实习阶段；承担内容安全垂类模型与审核大模型能力建设，并协同推进跨业务落地及团队成员培养。

项目 01　**严重度感知审核与自适应推理**

问题：隐含风险依赖多元素共现与上下文，二分类难以表达连续的违规程度，高吞吐场景又限制大模型推理成本。

方法：构建细粒度标签和严重度体系，以 SFT + RL 训练 VLM 排序能力；结合答案与过程奖励约束推理和结论的一致性。引入 Adaptive CoT，按样本难度分配推理开销；结合轻量召回与多模态排序架构上线。

产出：在社区与推荐安全场景落地，并将严重度排序、过度思考问题分别沉淀为第一作者及共同第一作者研究。

项目 02　**审核多模态大模型与结构化取证**

问题：通用 VLM 缺少审核领域知识，风险信息覆盖与幻觉控制存在权衡，输出还需供不同下游策略稳定解析。

方法：设计涵盖场景、主体、环境和细节的结构化取证模板；比较不同规模基础模型，采用 Caption with Box 监督微调与 OPD 蒸馏，增强风险感知、空间定位及输出稳定性。

产出：从零搭建审核取证能力与评估迭代流程，支持下游按需使用证据，推进内容理解与处置决策的解耦。

工程实践与技术沉淀

从领域模型到数据、训练与线上系统

更多代表项目

项目 03 **色情低俗模型的多标签重构与跨业务复用**

方法：将黑盒二分类规则拆解为通用多标签体系；联合优化 VLM 的生成与分类损失，以 Asymmetric Loss 和采样缓解长尾，并补充基于语言模型的文本风险识别能力。

产出：统一视频、封面、图文及社区等场景的基础识别能力，支持可调节的召回及处置策略，提升维护效率和失败案例可归因性。

项目 04 **图像检索与风险内容快速响应**

方法：将图像检索升级为召回与精排两阶段架构；基于 Fast-ReID、对比学习与 ArcFace 度量学习优化局部图、模糊图识别。结合 PFC 加速训练，并利用 Louvain 社区发现与 DBSCAN 聚类构建千万级训练数据。引入样本入库标准、历史数据清洗与动态阈值，改善样本库质量和误召问题。

应用：服务视频与图文风险内容检索，探索基于 Chinese CLIP 的文本检索图像能力，支持新风险类型的快速响应。

项目 05 **直播场景识别与大模型蒸馏**

方法：针对未成年人、血腥暴力等场景优化模型；重构年龄与未成年人识别方式，通过人脸检测、分类及卡通识别处理不同输入形态，减少非目标样本误召。将 VLM 的分类能力蒸馏到轻量视觉模型。

应用：在直播推理吞吐约束下改善识别效果，兼顾审核效率与安全覆盖，并复用到相关场景识别任务。

项目 06 **水印台标检测与可控样本合成**

方法：比较并迭代 YOLO 检测方案，针对类别分散、标注不足以及裁剪和模糊输入构建可控数据生成引擎；通过样本分布配置与增强策略提升模型鲁棒性和扩类效率。

应用：支持 90 余类水印台标识别，服务社区、视频、图文及版权相关业务。

项目 07 **数据生产引擎与可复用训练工具**

数据侧：搭建 Caption / QA 数据生产、人机协同细粒度标注与跨模型验证流程；围绕困难样本建立风格可控的生成和筛选流程，支持数据分布变化下的持续迭代。

训练侧：开发 vision-classification 工具，集成模型骨干、损失函数、数据增强、自定义 Trainer、分类与蒸馏任务；沉淀离线评估和训练流程，减少重复开发与人工操作。

专利相关成果

01 / 多模态　一种结合多模态数据的审核优化方法。

02 / 数据　一种对用于训练审核模型的训练样本挖掘方法。

03 / 部署　一种针对多模态审核模型的蒸馏部署方法。

04 / 审核　一种基于违规程度的细粒度审核系统。

05 / 可靠性　一种基于自我反省和跨模型验证的多模态可靠问答方法。

协作与研究方法

项目推进　承担模型 Owner 职责，参与目标拆解、方案选择、实验设计、效果评估和上线协同；指导正式员工与实习生开展模型及数据工作。

研究沉淀　围绕真实业务约束提出问题，通过消融实验和困难样本分析验证方案，再沉淀为论文、专利、训练工具与技术文档。

论文、竞赛与教育背景

图学习基础 / 多模态后训练 / 可靠推理 / 内容安全

已发表论文与公开预印本

2025 / 竞赛 **Improving VQA Reliability: A Dual-Assessment Approach with Self-Reflection and Cross-Model Verification**
Xixian Wu, **Yang Ou**, Pengchao Tian, Zian Yang, Jielei Zhang, Peiyi Li, Longwen Gao.
ICCV-CLVL 2025 Reliable VQA Challenge 第一名；公开预印本 arXiv:2512.14770。结合自我反省与跨模型验证提升回答可靠性。

2025 / 合作 **Identification of perceptive users based on the graph convolutional network**
Qiang Guo, Yong Luo, **Yang Ou**, Min Liu, Jian-Guo Liu.
Expert Systems with Applications. DOI: 10.1016/j.eswa.2024.125844.

2022 / 一作 **Identification of spreading influence nodes via multi-level structural attributes based on the graph convolutional network**
Yang Ou, Qiang Guo, Jia-Liang Xing, Jian-Guo Liu.
Expert Systems with Applications. DOI: 10.1016/j.eswa.2022.117515.

2022 / 一作 **Identifying spreading influence nodes for social networks**
Yang Ou, Qiang Guo, Jianguo Liu. *Frontiers of Engineering Management*（在线发表）。DOI: 10.1007/s42524-022-0190-8.

2022 / 合作 **Core-middle-periphery network model for China banking system**
Na Chen, Jianguo Liu, Yihui Chen, Ding Tu, **Yang Ou**, Mingzhu Jiang.
Frontiers in Physics. DOI: 10.3389/fphy.2022.981650.

在投研究

EMNLP 2026 **Rethinking Content Moderation via Severity-Aware Ranking**
Yang Ou, Jielei Zhang, et al. 第一作者。KUROKO 项目主页。

EMNLP 2026 **When Not to Think: Mitigating the Overthinking Effect in Content Moderation**
Yu Dai, **Yang Ou**, et al. 共同第一作者。

AAAI 2027 **Zero-Shot Detection for AI-Generated Images via Uncertainty-Aware Manifold Deviation**
Shutong Ding, **Yang Ou**, et al. 共同第一作者。

AAAI 2027 **LatentLite: Lightweight Latent Reasoning with On-Demand Explanations**
Bin Zhao, **Yang Ou**, et al. 共同第一作者。

ICLR 2027 **Reconstruct, Then Evolve: Grounded Data Synthesis for Harmful Meme Detection**
Bin Zhao, **Yang Ou**, Yihe Fan, Yuzhuo Zhang, Jielei Zhang, Junjie Wang, Qing Wang, Xudong Pan. 第二作者。

教育背景

2020–2023 **上海理工大学**，管理科学与工程硕士（2020.09–2023.03）。

2016–2020 **浙江万里学院**，电子商务学士（2016.09–2020.06）。